

FinBank

Plataforma de Datos end-to-end

Arquitectura de datos en Google Cloud Platform: de la base transaccional a los indicadores de negocio, con infraestructura como código, un pipeline por capas y gobierno de datos.

Google Cloud Platform

Terraform

Arquitectura Medallón

Cloud Workflows

Gobierno y seguridad

Qué construí y por qué

Una plataforma de datos completa, de punta a punta, sobre un dominio bancario realista.

El objetivo

Diseñar y construir una plataforma de datos completa: generación de datos sintéticos, infraestructura como código, un pipeline con arquitectura Medallón (Bronze, Silver y Gold), orquestación con dependencias y reintentos, y una capa de gobierno con roles, seguridad y alertas.

No busqué "la" solución perfecta: prioricé decisiones coherentes, supuestos documentados y un razonamiento técnico que se pueda explicar y sustentar.

Mis decisiones de fondo

- **Sector:** Banca y Servicios Financieros, por ser el dominio con reglas de negocio más ricas: mora, provisión regulatoria, transacciones sospechosas, CLTV.
- **Plataforma:** Google Cloud Platform, con foco en servicios serverless para aprovechar al máximo mi crédito de la capa gratuita.
- **Filosofía:** priorizar evidencia real — corridas en la nube, pruebas de acceso por impersonación — sobre documentación puramente declarativa.

• Setup

• Datos y modelo

• Infraestructura


• Pipeline Medallón

• Orquestación

• Gobierno y calidad

Flujo de datos de punta a punta

De la base transaccional a los indicadores de negocio, en cuatro etapas con calidad creciente.



- Orquestado por **Cloud Workflows + Scheduler** , todos los días a las 02:00
- Gobernado por **IAM** , **Secret Manager** y **Cloud Monitoring**

44+

recursos de infraestructura aplicados

8

modelos analíticos en Gold

43/43

pruebas de calidad en verde

3

roles de acceso verificados


Servicios elegidos en GCP

Un criterio guió cada elección: máxima cobertura funcional, mínimo costo fijo por hora.

NECESIDAD	SERVICIO ELEGIDO	MOTIVO
Almacenamiento Bronze	Cloud Storage	Bronze son archivos crudos en la nube
Almacenamiento Silver / Gold	BigQuery	Serverless, sin clúster con costo por hora
Procesamiento Silver / Gold	dbt + BigQuery	Tests, documentación y linaje con poco esfuerzo extra
Orquestación	Cloud Workflows + Scheduler + Run	Serverless, sin el costo fijo de un orquestador gestionado
Base de datos origen	Cloud SQL (PostgreSQL 16)	Motor estándar para carga transaccional
Infraestructura como código	Terraform	Estándar del mercado, backend remoto nativo
Gestión de secretos	Secret Manager	Ninguna credencial en el código
Notificaciones	Cloud Logging + Monitoring	Logs estructurados y alertas, sin componentes extra

Arquitectura actual en la nube

Los mismos componentes que están corriendo hoy: cómputo, almacenamiento, orquestación y seguridad.



SEGURIDAD Y OBSERVABILIDAD — SOPORTAN TODO EL FLUJO



- Los datos avanzan en línea recta: **SQL** → **Storage** → **BigQuery** , un Cloud Run Job por capa
- Todo corre bajo el mismo control diario, sin intervención manual

Un modelo de datos realista, no aleatorio

Seis tablas fuente, con distribuciones estadísticas y anomalías controladas e intencionales.

Clientes

10.000 registros, edad distribuida normal, score de crédito correlacionado con segmento

Productos

50 productos en familias de crédito, ahorro y transaccional

Movimientos

500.000 registros, picos horarios y de quincena, montos log-normales

Obligaciones

30.000 registros, mora con cola exponencial

Sucursales

200 puntos en 14 ciudades de 5 países

Comisiones

80.000 registros de cobros por producto

Realismo de los datos

- Semilla fija: 100% reproducible
- 12 meses de histórico con estacionalidad
- Nulos controlados en campos no críticos
- Integridad referencial garantizada por diseño
- 3 formatos de salida: CSV, JSON y Parquet

Anomalías intencionales

- Duplicados exactos
- Fechas fuera de rango
- Llaves foráneas huérfanas
- Campos inconsistentes entre sí

Así llegan los datos, antes de transformarlos


Seis tablas relacionales tal como viven en Cloud SQL, con sus llaves primarias y foráneas.



- Cada línea es una relación **1 a N** : un cliente o producto puede tener muchos registros
- Las llaves huérfanas y duplicadas son anomalías intencionales, validadas en Silver

Arquitectura de modelado dimensional

Dimensiones conformadas, compartidas por varias tablas de hechos.



Dimensiones conformadas

Las cuatro dimensiones son compartidas por varias tablas de hechos: la misma tabla de clientes sirve a transacciones, cartera y rentabilidad. Es la base del modelado dimensional tipo Kimball.

Patrón destacado: snapshot periódico

La tabla de KPI diario agrega una fila nueva por día, producto, segmento y ciudad en cada corrida, en vez de sobrescribir el historial. Así el indicador "diario" realmente acumula una serie de tiempo.

Reglas de negocio y calidad por capa

Cada capa tiene un propósito claro; los datos no se saltan niveles.

B

Bronze

- Copia cruda, sin transformar el esquema
- Columnas de auditoría: ingesta, sistema, lote
- Particionado por fecha
- Modo incremental con marca de agua

S

Silver

- Deduplicación y tipado estándar
- Integridad referencial validada
- Datos personales protegidos con hash
- Indicador de movimiento sospechoso
- 21 pruebas de calidad en verde

G

Gold

- 4 dimensiones, 3 hechos, 1 KPI
- Mora y provisión regulatoria A-E
- Valor de vida del cliente (CLTV)
- Particionamiento y clustering
- 22 pruebas adicionales (43 en total)

- Linaje documentado de **10 campos calculados**
- Calidad de datos entre **99.4% y 100%** de conformidad por tabla

Un pipeline confiable, no solo funcional

Dependencias explícitas, reintentos con espera progresiva y 3 alertas operacionales verificadas.



Confiabilidad

- Ejecución programada diaria, siempre a la misma hora
- 3 reintentos con espera progresiva entre intentos
- Tiempo máximo de espera por tarea
- Un fallo detiene las capas siguientes de forma explícita

3 alertas verificadas con evidencia real

- **Fallo de tarea**, con el DAG, la tarea y el error exactos
- **Reporte diario de éxito**, con registros por capa y duración
- **Anomalía de volumen**, comparada contra el promedio reciente

- 2 corridas exitosas, con tiempos completos registrados
- 1 falla forzada, detuvo Silver y Gold correctamente
- Terraform corrigió el desvío al revertir la falla

Acceso controlado y verificado

Cada rol tiene su propia identidad de servicio; el control de acceso se probó de forma real, no solo declarado.

ROL	BRONZE	SILVER	GOLD
Ingeniero de datos	Permitido	Permitido	Permitido
Analista	Denegado	Denegado	Permitido
Administrador	Control total del proyecto		

Seguridad y trazabilidad

- Contraseñas en el gestor de secretos, nunca en código
- Registro de auditoría sobre cada acceso a los datos
- Datos personales protegidos desde Silver en adelante
- Catálogo de datos: tabla, campo, tipo, origen, sensibilidad
- Cada componente corre con el permiso mínimo necesario

- Acceso denegado comprobado con una identidad real, no solo declarado
- Cambios registrados en un historial con fecha y descripción
- Linaje documentado de **10 campos** calculados en Gold

De punta a punta, con evidencia real

Las cinco fases completas, verificadas en la nube, no solo código escrito.

44+

recursos de infraestructura
reales

497K+

movimientos procesados

43/43

pruebas de calidad de datos

3/3

alertas operativas verificadas

El mayor reto que resolví

Al probar el acceso del rol Analista a Gold, la tabla no aparecía, ni siquiera para mí como dueño del proyecto. Investigando a fondo encontré que los modelos de Gold se estaban guardando por error en el dataset de Silver, por un detalle mal configurado en las transformaciones. Lo corregí, reconstruí los modelos en el lugar correcto y volví a correr el pipeline completo para confirmarlo en producción.

Cierre

Quedo disponible para profundizar en cualquier decisión técnica, mostrar evidencia adicional o recorrer el código en vivo.

Repositorio

[github.com/AndresLAraque/
ArquitecturaDatosModeladoBancario](https://github.com/AndresLAraque/ArquitecturaDatosModeladoBancario)

Documentación completa

README.md y PLAN.md

Autor

Andrés Araque